实验 5：LLM、Context 与 RAG 实现

姓名：罗心月　　学号：24111302025　　班级：一班

1. 实验目的

- 编写并运行模型调用代码，掌握输入组织、结构化输出校验和调用失败处理。
- 完成资料切分、检索、上下文组织、回答生成与来源引用，理解 RAG 各环节的作用。
- 使用固定问题集对比直接调用模型与使用 RAG 的回答，分析效果与局限。

2. 实验内容

2.1 LLM 调用与输出格式

- 选择一个知识问答任务，说明用户问题、输入内容和结果用途；结合个人软件时，注明对应个人软件的用户故事。
- 编写并运行云端模型调用代码，记录模型名称、调用方式、配置和主要参数，展示完整输入与返回结果，并测试至少一种连接失败、接口不可用或超时情况。
- 运行至少 3 组输入，包含正常问题、缺少必要信息的问题和超出任务范围的问题，记录期望与实际结果。缺少信息时提示补充或追问，超出范围时按任务要求提示无法处理。

2.2 Prompt 与上下文组织

- 编写可重复使用的 Prompt 模板，区分任务要求和用户问题，明确回答格式及信息不足时的处理。完成 RAG 后加入检索资料与来源，多轮对话按需加入历史消息，并展示一份实际发送给模型的完整输入。
- 根据测试结果修改至少一次 Prompt，记录原版本、修改原因、修改内容和结果变化；结论限于本次样例，未改善或出现退步也应记录。
- 检查输入中是否存在无关或重复信息，按需精简并记录检查结果；有删减时比较长度与回答变化。选择和组织模型输入信息称为上下文工程；长度可用字符数或 Token 数。

2.3 知识库与切分策略

- 根据个人软件选择少量、来源明确的资料作为知识库；记录数量、格式、使用权限和隐私处理方式，清理乱码、重复及无关内容，不得向外部模型发送敏感数据。
- 按段落、标题或长度切分文本，说明片段大小、相邻片段是否重叠以及资料更新方法。
- 抽查至少 3 个片段，展示内容与元数据，检查关键语句是否完整、来源是否对应原资料。发现问题时调整切分方式并重新检查。

2.4 检索与 RAG 最小链路

- 实现关键词检索、向量检索或二者结合的方法，并说明选择理由。关键词检索按词语匹配；使用向量检索时，用同一嵌入模型分别将资料片段和用户问题转为数值向量，再比较相似程度，记录模型名称与比较方法。
- 展示一次查询、按相关性排序的前 k 个片段（Top-k）及排序依据，说明 k 的取值。返回片段不代表资料相关，应说明判断方法，如关键词匹配规则、经样例检查的相似度阈值或模型判断；无结果或资料不相关时，返回资料不足提示。
- 将检索片段与来源编号加入上下文，生成带出处的回答，检查引用是否对应原片段、是否支持回答；资料不足时明确提示，不编造答案或引用。
- 完成“问题输入—检索—上下文组织—模型调用—回答返回”的流程，保存检索片段、实际上下文和最终回答。

2.5 对比测试与质量分析

- 建立 5—8 个固定问题及判断规则，包含单片段可回答、多片段综合，以及资料无答案或含义不清的情况，写明处理方式，供后续实验重复使用。
- 两组使用相同问题、模型、主要参数和基本输出格式：直接模型组不提供检索资料，RAG 组增加资料及依据资料回答、引用来源的要求。说明两组提示词的差异；各次测试使用独立上下文，避免前一次结果影响后一次测试。
- 用统一表格记录两组回答和人工判断，比较正确性、要点遗漏和无依据内容，另检查 RAG 组的引用可靠性。资料无答案时，区分模型凭已有知识回答与资料能够支持回答。
- 记录从输入到返回结果的耗时，以及可获取的 Token 数或调用次数；收费接口补充实际或估算费用。

2.6 模块调用与后续使用

- 将检索和回答生成整理为可调用的模块，说明依赖、调用方式、输入、输出及失败返回，并提供知识库准备方法。
- 提供页面、接口或命令行入口，演示从输入问题到显示回答与出处的完整过程。
- 说明个人软件是否继续使用 RAG 及理由，需要时指出拟接入的功能；列出当前局限和下一步改进计划。

3. 操作记录

截图、代码和日志等必须编号并配文字说明。

3.1 任务与模型调用

问答任务是“StudyPilot 资料问答”：用户用自然语言问项目或课程学习相关的问题，系统从本人编写的项目文档里检索资料，给出带出处的回答。结果用途是复习和查资料，不直接写入学习计划。对应的用户故事是实验 2 里的“作为本科生，我希望把课程要求转换成可修改的学习计划，以便按时完成任务并了解自己的薄弱知识点”，本实验补充的是其中的查资料环节。

模型调用代码在 `backend/app/service/llm_client.py`，用 httpx 调用 DeepSeek 的 Chat Completions 接口，密钥只从环境变量 `DEEPSEEK_API_KEY` 读取，不写进代码和日志。

表 5-1: 模型调用参数

项目	设置
模型名称	`deepseek-chat`（官方旧别名，实际由 DeepSeek-V4.1-Flash 提供）
调用方式	HTTP POST，`https://api.deepseek.com/chat/completions`
主要参数	temperature 0.2（任务解析用 0）、max_tokens 700—900、stream=false、超时 60 秒
结构化输出	RAG 回答开启 `response_format=json_object`，再用 Pydantic 校验字段
密钥管理	环境变量 `DEEPSEEK_API_KEY`，日志和截图只显示前 6 位与后 3 位

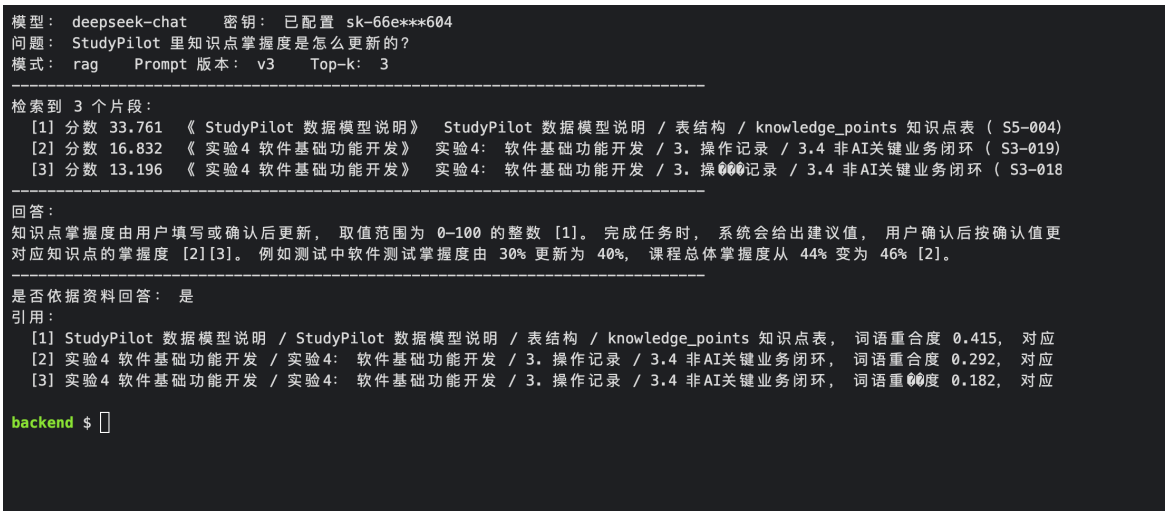


图 5-1: 一次完整调用：检索片段、回答与出处

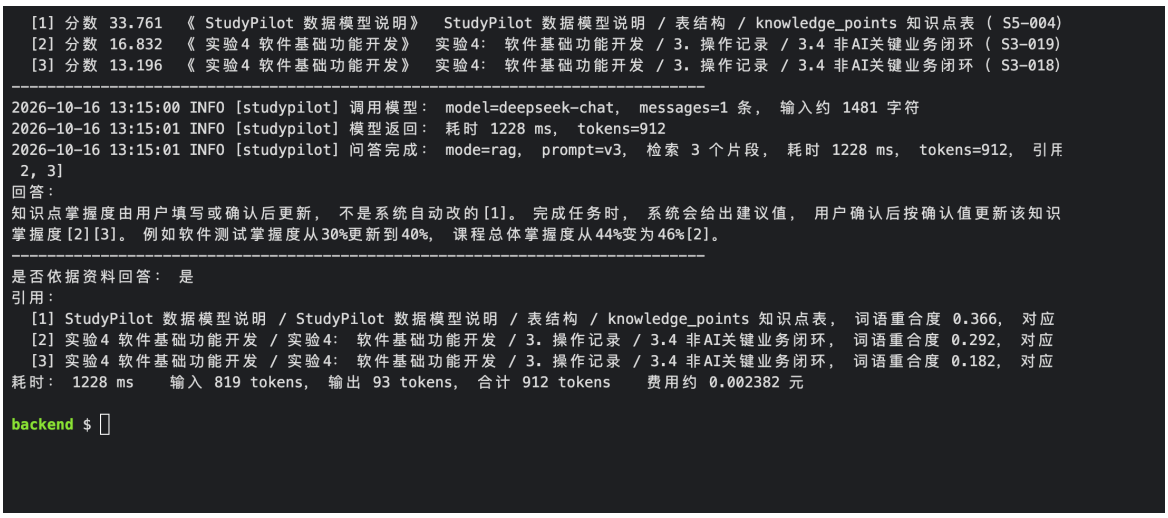


图 5-2: 调用返回：引用核对与 Token、耗时、费用

调用失败处理按类型区分，接口返回统一结构的错误信息，程序不会中断。

表 5-2: 三种调用失败情况的实测结果

情况	错误码	提示信息	接口返回
API Key 无效	LLM_AUTH_FAILED	模型服务鉴权失败（401），请检查 API Key	HTTP 502
响应超时（超时设为 1 毫秒）	LLM_TIMEOUT	模型服务响应超时（ConnectTimeout），请稍后重试	HTTP 504
服务地址不可达	LLM_CONNECTION_ERROR	无法连接模型服务，请检查网络或服务地址	HTTP 503



图 5-3: 调用失败实测：鉴权失败、超时、地址不可达

结构化输出用“把自然语言学习要求解析成任务”来验证：字段为 title、minutes、date、point，日期用正则约束为 YYYY-MM-DD。正常输入一次通过；故意换成模型无法满足的结构（要求 priority、owner 字段）时，第一次校验失败，程序把校验错误回传给模型并要求只返回合法 JSON，第二次通过，整个过程耗时 1565 毫秒、386 tokens。



图 5-4: 结构化输出：正常解析与校验失败后重试

三组输入的实测结果如下。第一组是正常问题，第二组缺少必要参数（第一版 Prompt 会直接讲设计内容，v3 修正后改为追问），第三组超出问答范围，检索没有达到阈值，直接返回资料不足，不调用模型。

表 5-3: 三组输入的期望与实际结果

类型	输入	实际结果
正常问题	StudyPilot 里知识点掌握度是怎么更新的?	回答“由用户填写或确认后更新，不是系统自动改的”，并给出三处引用
缺少必要信息	帮我设置考试目标	先说明无法直接设置，再列出需要补充的课程、考试日期、目标分数、每天可用时间
超出任务范围	帮我写一首关于春天的诗	检索无结果，返回“资料不足：知识库中没有找到与该问题相关的内容”，未调用模型

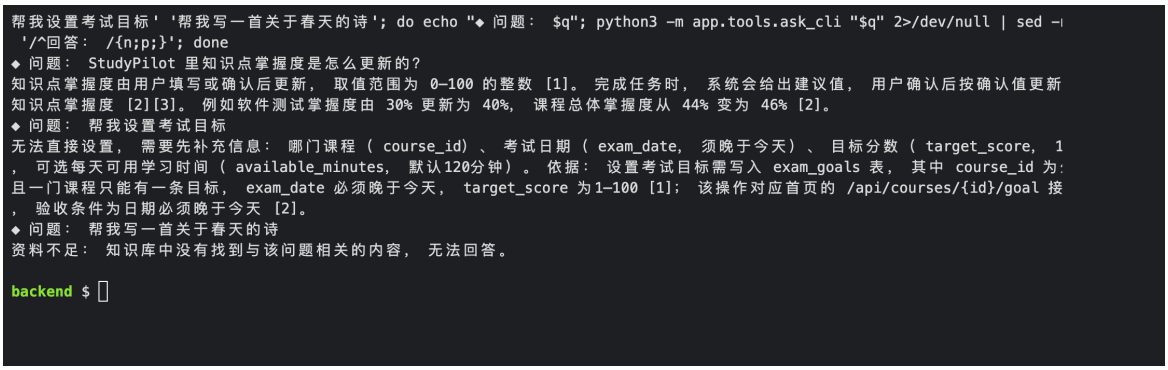


图 5-5: 三组输入的实际反馈

3.2 Prompt 与上下文组织

Prompt 模板放在 backend/app/service/prompts.py，任务要求与用户问题分开：模板里写清回答范围、长度、引用格式、信息不足和超范围时的处理，最后才是资料和用户问题。版本变化见表 5-4，实际发送给模型的完整输入见图 5-6 和图 5-7。

表 5-4: Prompt 修改记录

版本	原版本问题	修改内容	结果变化
v1	RAG 只写“请根据资料回答问题”	无格式要求，模型自由发挥	回答偏长、用 Markdown 罗列，没有编号引用，出处无法核对
v2	回答长度和引用不规范	增加只依据资料、250 字以内、句末标注[1]、资料不足时置 sufficient=false、只输出 JSON	回答变短，引用可直接核对到片段；无答案时明确说资料不足
v3	缺少参数的操作请求（如“帮我设置考试目标”）被当成普通问题回答	增加一条：操作请求缺少参数时先列出需要补充的信息	同一问题改为追问课程、考试日期、目标分数、每天可用时间



图 5-6: Prompt v1（上）与 v2（下）对同一问题的回答对比

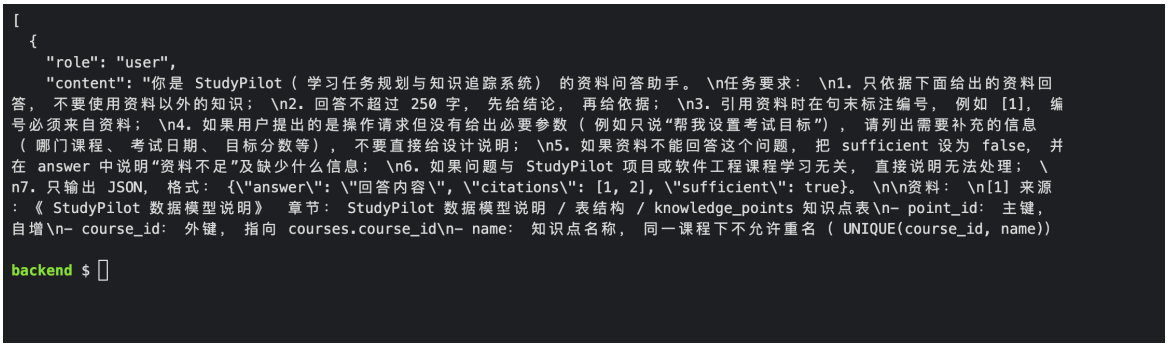


图 5-7: 实际发送给模型的输入：任务要求与资料编号

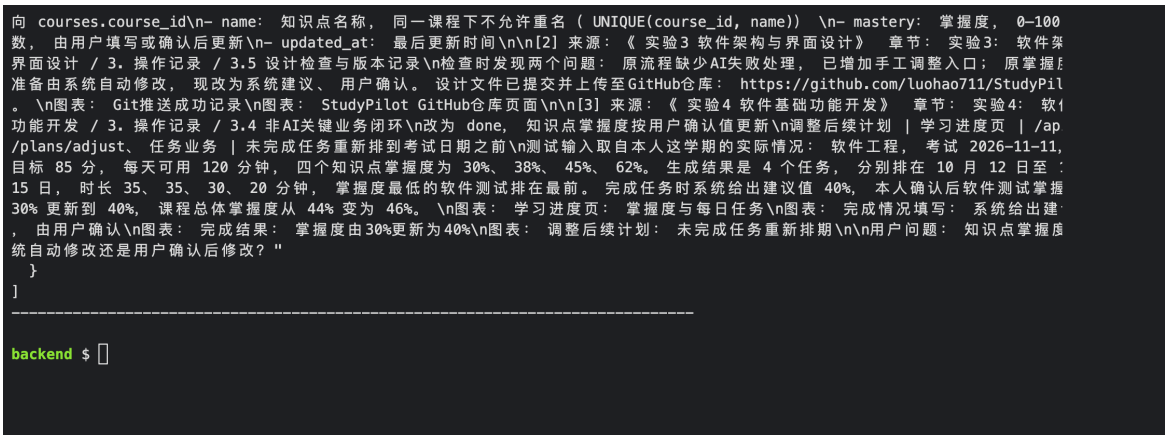


图 5-8: 实际输入中的资料内容与用户问题

上下文检查发现两类问题：一是检索排在后面的片段与问题无关（例如问架构却带回 LaTeX 编译命令），二是相邻片段有 80 字重叠，同一句话可能在上下文里出现两次（本次样例重复 25 字）。按“分数不低于最高分 60%”精简后，上下文从 955 字降到 604 字（减少 37%），prompt tokens 从 805 降到 612，回答和引用都没有变化。

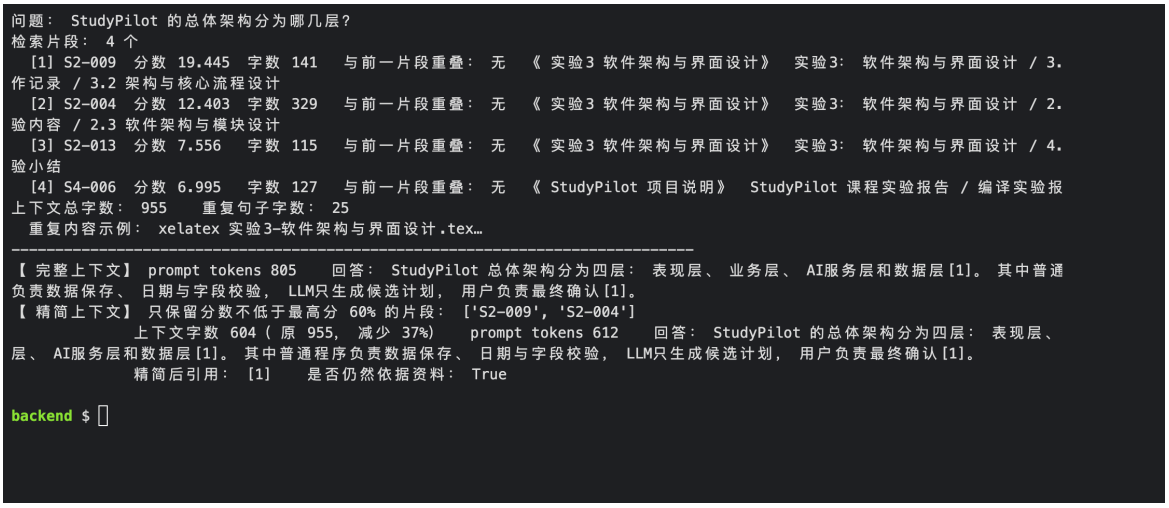


图 5-9: 上下文检查：无关片段、重复内容与精简前后对比

3.3 知识库与切分策略

知识库共 5 篇资料，全部是本人编写的项目文档，来源明确、可以公开，不包含他人隐私和密钥。资料清单放在 `backend/kb/sources.json`，每条记录使用权限和隐私处理方式。

表 5-5: 知识库资料清单

编号	资料	来源文件	字数	片段数
S1	实验 2 个人软件选题与需求分析	reports/experiment2/…tex	3957	17
S2	实验 3 软件架构与界面设计	reports/experiment3/…tex	3025	13
S3	实验 4 软件基础功能开发	reports/experiment4/…tex	7179	29
S4	StudyPilot 项目说明	README.md	991	7
S5	StudyPilot 数据模型说明	backend/kb/source/数据模型说明.md	1696	8

清理与切分：LaTeX 报告先转成纯文本，去掉导言区、命令和图片，表格按行转成“单元格 | 单元格”，图只有标题时保留“图表：标题”一行；然后按标题切成小节，小节内按段落合并到 420 字左右，同一小节被切开时保留上一片段末尾 80 字作为重叠。更新方法是修改源文件后重新执行 `python3 -m app.tools.build_kb`，片段编号会重新生成。



图 5-10: 知识库构建结果：5 篇资料、74 个片段

抽查了 3 个片段：S2-009（架构分层，141 字，无重叠）、S5-004（知识点表字段，157 字，无重叠）、S3-019（掌握度更新与验收，有重叠）。检查结果：关键句子完整，“系统分为表现层、业务层、AI 服务层和数据层”没有在切分处断开；来源路径、章节和更新时间都能对应回原资料；带重叠的片段开头确实重复了上一片段的结尾，用于避免跨片段的问题漏检。



图 5-11: 片段抽查一：S2-009 与 S5-004 的内容与元数据

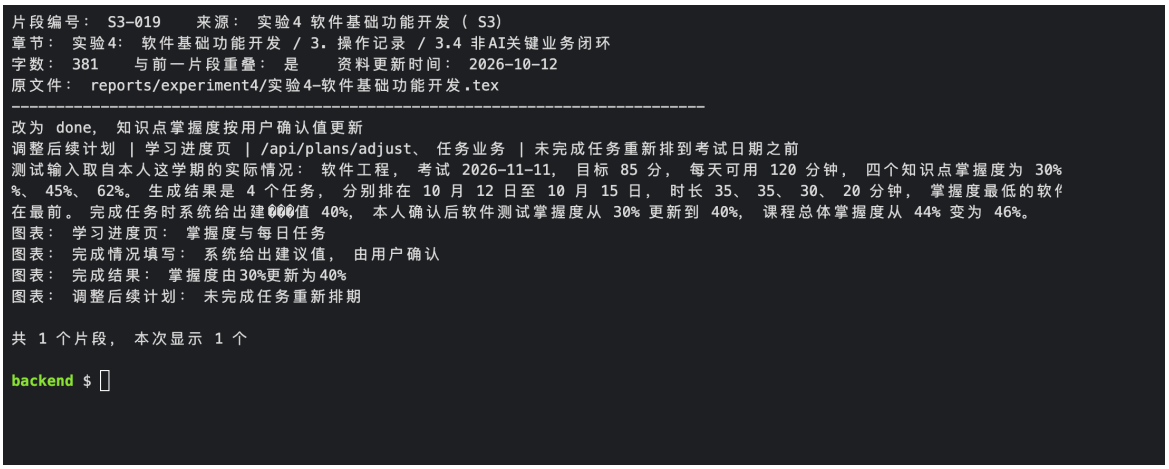


图 5-12: 片段抽查二：S3-019 的内容与重叠标记

3.4 检索与 RAG 最小链路

检索用关键词方法：中文按二字切分、英文按单词切分，用 BM25 排序（k1=1.5，b=0.75），并加入标题字段加权和同义词扩展。选择理由是没有配置嵌入模型，资料量只有几十个片段，关键词检索的排序依据可以逐项核对，不需要额外的模型服务。主要参数见表 5-6。

表 5-6: 切分与检索参数

项目	取值与说明
片段大小	420 字，相邻片段重叠 80 字
分词方式	中文二字组合 + 英文单词，去停用词
排序方法	BM25，标题字段权重 1.2
同义词扩展	权重 0.6，例如“数据库 → 表/字段/主键/外键”
相关性阈值	10 分，低于阈值视为没有相关资料
Top-k	默认 3，页面可调 1—8

阈值是抽查后定的：有答案的问题最高分在 15.9—33.2 之间，与项目无关的问题在 6.9 分以下，取 10 分可以分开这两类；话题相关但资料没有答案的问题落在中间，交给模型判断并把 sufficient 置为 false。

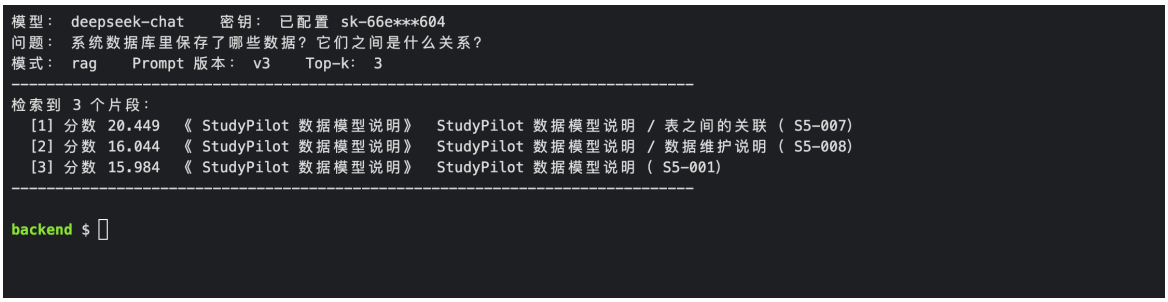


图 5-13: 一次查询的 Top-3 片段与 BM25 分数

样例检查发现过一次检索失败：问“系统数据库里保存了哪些数据？它们之间是什么关系？”时，前 3 个片段都是实验 3 的设计说明，没有检索到数据模型的内容，回答只能给出资料不足。原因是问题和资料用词不一致（问“数据库、数据”，资料里写的是“表、字段、主键”），而且正文里的通用词太多。加入标题加权和同义词扩展后，数据模型说明的“表之间的关联”片段排到第 1，回答也正确了。

表 5-7: 检索改进前后对比（同一个问题）

阶段	Top-3 片段（分数）	回答情况
改进前	S2-004(11.2)、S2-001(7.4)、S2-006(6.1)	资料不足，未回答
改进后	S5-007(20.4)、S5-008(16.0)、S5-001(16.0)	正确列出用户、课程、考试目标、知识点、计划、任务及关联，并给出引用

回答生成后做引用核对：检查编号是否在检索结果范围内，并计算被引用片段与回答的词语重合度，低于 0.12 标记为需要人工复核，编号越界直接判为不可靠。本轮对比测试中 RAG 组共引用 12 处，逐条检查全部对应。

资料不足分两种处理：检索完全没有结果时（如“项目开发一共花了多少钱”）直接返回资料不足，不调用模型；检索到了片段但资料回答不了时（如“用的是哪种知识追踪算法”），把 sufficient 置为 false，并在回答里说明缺少什么信息。



图 5-14: 页面入口：RAG 回答、出处与检索片段



图 5-15: 资料不足时的回答：说明缺少什么信息，不编造

3.5 对比测试与质量分析

固定问题集放在 backend/tests/data/compare_questions.json，共 8 题：4 题单片段可回答、2 题多片段综合、2 题资料无答案。判断规则写明每题需要覆盖的要点；资料无答案的两题，正确做法是说明资料不足，不能编造数字或算法名称。两组使用相同的问题、模型和 temperature（0.2），RAG 组多出资料和引用要求，每次调用都是独立的单轮对话。

表 5-8: 对比测试逐题结果（Prompt v3，Top-k=3；耗时与 Tokens 两列为“直接/RAG”）

编号	类型	问题	要点				
直接	要点						
RAG	引用	耗时 ms	Tokens				
Q1	单片段	总体架构分为哪几层	2/3	3/3	1	1395 / 1473 ms	228 / 742
Q2	单片段	掌握度自动修改还是用户确认	1/2	2/2	2	1598 / 978 ms	199 / 849
Q3	多片段	模型不可用时计划怎么生成	0/2	2/2	2	1237 / 1318 ms	188 / 860
Q4	单片段	MVP 不实现哪些功能	0/2	2/2	2	1590 / 1061 ms	226 / 927
Q5	多片段	测试覆盖哪几类异常	0/2	2/2	2	1251 / 984 ms	189 / 943
Q6	多片段	数据库保存哪些数据及关系	3/3	3/3	2	1430 / 1280 ms	214 / 704
Q7	资料无答案	用的是哪种知识追踪算法	未声明资料不足	声明资料不足	1	1451 / 1074 ms	203 / 378
Q8	资料无答案	开发花了多少钱	未声明资料不足	声明资料不足(未调用模型)	0	1071 / 0 ms	175 / 0

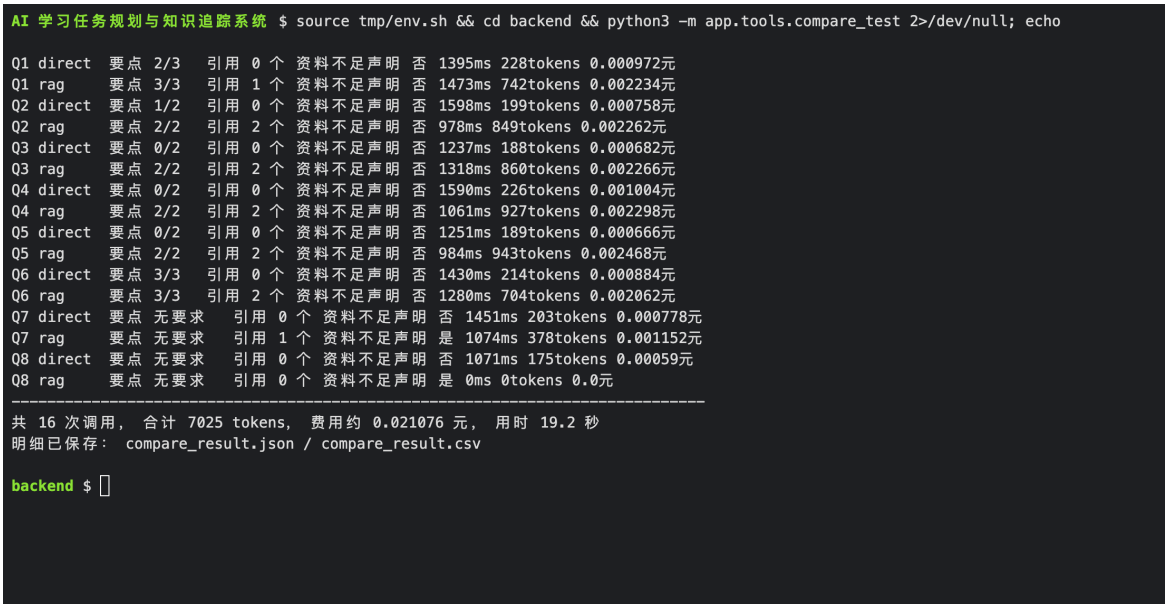


图 5-16: 对比测试运行结果：16 次调用，7025 tokens，约 0.021 元

本次共执行 16 次调用（Q8 的 RAG 组因检索无结果未调用模型），合计 7025 tokens，按输入 2 元/百万、输出 8 元/百万估算约 0.0211 元，总用时 19.2 秒。RAG 组单次约 0.0021—0.0025 元、700—950 tokens，直接模型组约 0.0006—0.0010 元、180—230 tokens，RAG 的输入 tokens 约为直接模型的 3 倍，费用和耗时都更高。

人工检查回答内容，主要差别有三点。第一是正确性：直接模型在项目专属问题上

给出了看似合理但和项目不符的内容，例如 Q1 把架构说成“交互层、应用层、领域服务层、数据层”（项目实际是表现层、业务层、AI 服务层、数据层），Q6 说有“测验/错题”表（项目没有），属于无依据内容；RAG 组的回答都能在原片段里找到对应句子。第二是资料无答案时的处理：直接模型 Q7 说无法确认、Q8 说超出范围，都没有明确说明“资料不足”，而 RAG 组两题都说明了资料不足并列出缺少的信息，没有编造。第三是引用可靠性：RAG 组 12 处引用全部能对应到检索片段，词语重合度在 0.12—0.52 之间。

也有 RAG 答得不如直接模型的地方：Q2 中直接模型虽然结论不准确，但提示了“建议查看需求文档中的知识追踪模块”，而 RAG 的回答只在资料范围内作答；Q5 的要点命中在人工核对时发现，RAG 给出的两个例子都正确，但异常类别的表述不如直接模型的分类完整。这些说明 RAG 的作用是把回答限制在资料范围内、并提供可核对的出处，不能代替人工判断内容是否准确。

3.6 模块调用与后续使用

检索和回答生成整理成可调用模块，依赖关系和失败返回见表 5-9。知识库准备方法：把资料登记到 `backend/kb/sources.json`，执行 `python3 -m app.tools.build_kb` 生成 `chunks.jsonl` 即可；资料更新后重新执行同一条命令。

表 5-9: 模块、输入输出与失败返回

模块	依赖	输入与输出	失败返回
`qa_service.answer_question`	retriever、prompts、llm_client	问题、模式、Top-k、Prompt 版本 → 回答、引用、检索片段、耗时、tokens、费用	空问题 400、问题过长 400、知识库未构建 400
`retriever.search`	kb_service	问题、Top-k、阈值 → 按分数排序的片段	无结果时返回空列表
`kb_service.build_index`	sources.json	资料清单 → chunks.jsonl 与索引元数据	资料文件缺失 500
`llm_client.chat`	httpx	messages、模型参数 → 内容、用量、耗时	未配置 503、连接失败 503、超时 504、鉴权失败 502、限流 503、返回结构异常 502
`llm_client.chat_json`	Pydantic	messages、输出结构 → 校验后的对象	两次都不合法 502

入口有页面、接口和命令行三种：页面是 `/api/qa/ask` 对应的“资料问答”页（RAG/直接模型可切换，显示回答、出处、检索片段、耗时和费用）；接口为 `POST /api/qa/ask`、`GET /api/qa/kb`、`GET /api/qa/kb/chunks`、`POST /api/qa/kb/rebuild`；

命令行包括 ask_cli（问答，可打印检索结果和完整输入）、build_kb、inspect_chunks、compare_test、context_check、fail_demo、parse_task。另外增加了 10 个离线单元测试，和实验 4 的 10 个用例一起共 20 个，全部通过。



图 5-17: 页面入口：直接模型模式（不给资料）的回答



图 5-18: 页面入口：超出范围的问题返回资料不足

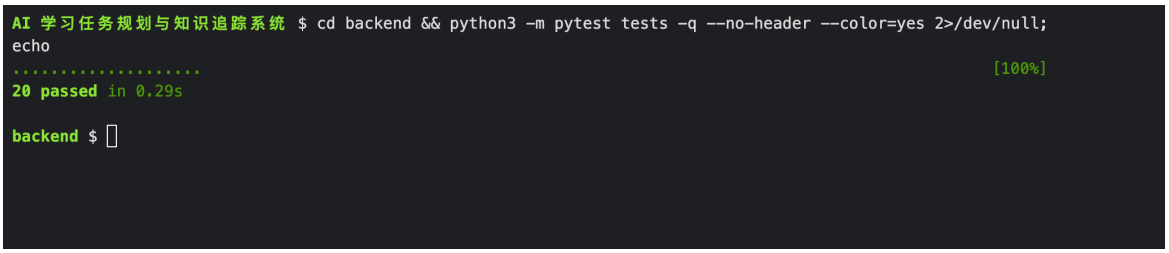


图 5-19: 单元测试：20 个用例全部通过



图 5-20: 运行日志：模型调用、返回用量与检索无结果

结论是继续在 StudyPilot 中使用 RAG，作为“资料问答”功能保留，但只作为参考，不直接生成或修改学习计划。当前局限：一是关键词检索对用词差异敏感，同义词表靠手工维护；二是中文按二字切分会产生无意义组合，可能误匹配；三是知识库只有 5 篇项目文档，没有教材内容，回答范围有限；四是引用核对只看词语重合度，不能完全判断语义是否支持回答；五是 RAG 的费用和耗时约为直接模型的 3 倍。下一步计划：把 ER 图等图片内容补充成文字资料，加入课程复习资料；把 8 个固定问题作为回归测试集，修改 Prompt 或检索参数后自动跑一遍对比；后续再考虑关键词与向量检索结合。

3.7 版本记录

代码和报告都提交到 GitHub 仓库 https://github.com/luohao711/StudyPilot，本实验对应 tag `v0.3`。

```
AI 学习任务规划与知识追踪系统 $ git log --oneline --decorate -6 && echo && git tag -n1
7fe795a (HEAD -> main, tag: v0.3) 实验5： 实现资料问答（ 模型调用、 Prompt迭代、 知识库切分、 BM25检索与RAG对
试）
d11d97a (origin/main) 实验4： 补充推送记录与仓库页面截图
19a3e17 实验4： 完成报告正文、 运行截图与最终PDF
c390c38 (tag: v0.2) 实验4修订版： 修复进度页完成提示， 补充运行说明
dbf3c0a 修正计划生成服务： 补充校验、 按掌握度分配时长并限制在考试日期前
895bed0 实验4： 实现考试目标、 知识点、 学习计划与每日任务接口及前端页面

v0.1            实验4可运行初版
v0.2            实验4测试修订版
v0.3            实验5 RAG资料问答

AI 学习任务规划与知识追踪系统 $
```

图 5-21: 版本记录：本实验对应的 Commit 与 Tag

```
 '--- 第' $i '次失败， 重试 ---'; sleep 10; done
fatal: unable to access 'https://github.com/luohao711/StudyPilot.git/': Failed to connect to github.com port 443 after
 75003 ms: Couldn't connect to server
--- 第 1 次失败， 重试 ---
Enumerating objects: 97, done.
Counting objects: 100% (97/97), done.
Delta compression using up to 8 threads
Compressing objects: 100% (73/73), done.
Writing objects: 100% (77/77), 10.94 MiB | 2.88 MiB/s, done.
Total 77 (delta 13), reused 0 (delta 0), pack-reused 0 (from 0)
remote: Resolving deltas: 100% (13/13), completed with 12 local objects.
To https://github.com/luohao711/StudyPilot.git
   d11d97a..7fe795a  main -> main
 * [new tag]         v0.3 -> v0.3

AI 学习任务规划与知识追踪系统 $
```

图 5-22: 推送到 GitHub 的记录

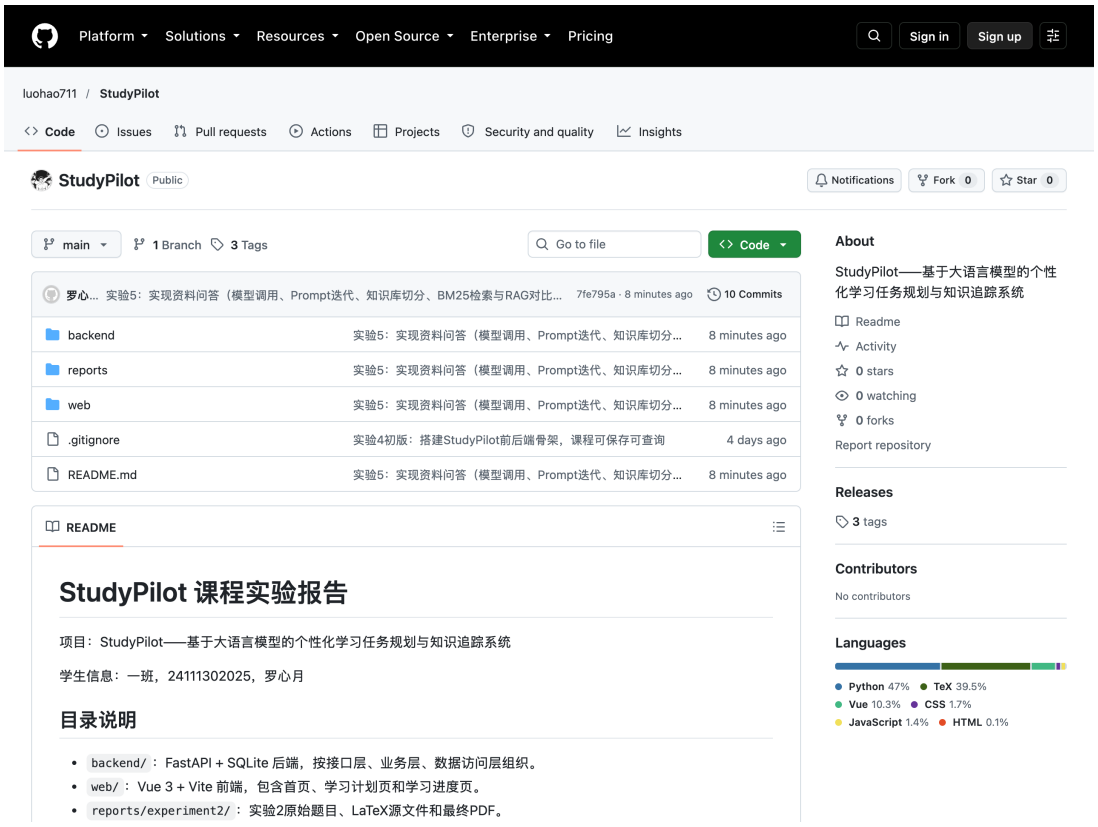


图 5-23: StudyPilot 仓库页面

4. 实验小结

本次完成了 StudyPilot 的资料问答功能：用 DeepSeek 的 deepseek-chat 接口做模型调用，把 5 篇项目文档转成 74 个片段的知识库，用 BM25 关键词检索做检索，再让模型依据检索到的片段生成带出处的回答，前端加了一个“资料问答”页面，命令行和接口也都能调用。

过程中主要做了三件事。第一是 Prompt 改了两次：初版没有格式要求，回答发散、没有引用；第二版要求只依据资料、限制长度并输出 JSON，引用可以逐条核对；测试三组输入时又发现“帮我设置考试目标”这类缺少参数的操作请求会被当成普通问题回答，于是加了追问规则。第二是知识库补了一次：抽查时问“数据库保存了哪些数据”答不上来，因为实验 3 的 ER 图是图片，文字里没有表结构，补了一份数据模型说明后回答正确，也说明资料覆盖范围决定了 RAG 的上限。第三是检索调了两次：加入标题加权和同义词扩展后，同一个问题的正确片段从检索不到变成排在第 1。

对比测试用 8 个固定问题跑了 16 次调用，共约 0.021 元。直接模型在项目专属问题上会给出看似合理但不符实际的内容（架构分层名称、并不存在的表），RAG 的回答都能对应到原片段并给出引用，两个资料无答案的问题也都明确说明资料不足。局限是关键词检索依赖用词、知识库范围有限、RAG 的费用和时间约为直接模型的三倍，后续用

固定的 8 个问题做回归测试，并考虑补充资料和结合向量检索。